

Entrega Aula 01

Ambiente, Datasets Abertos e Princípios FAIR

ACESSAR O REPOSITÓRIO COMPLETO
<https://github.com/B073LH0/detector-de-parkinson>

Visão geral

Projeto acadêmico reproduzível para explorar características acústicas da voz potencialmente associadas à doença de Parkinson. A entrega documenta a fonte dos dados, organiza um ambiente Python verificável e prepara uma análise exploratória rastreável. O trabalho não propõe diagnóstico médico nem substitui avaliação clínica.

Pergunta de pesquisa

Características acústicas extraídas da voz apresentam diferenças mensuráveis entre indivíduos com doença de Parkinson e controles saudáveis e podem contribuir para diferenciar os dois grupos?

Dataset selecionado

Campo	Informação verificada
Nome	Parkinson Dataset with replicated acoustic features
Fonte	UCI Machine Learning Repository - dataset 489
DOI	10.24432/C5701F
Licença	Creative Commons Attribution 4.0 International (CC BY 4.0)
Amostra	80 participantes: 40 com Parkinson e 40 controles
Registros	240 gravações - três réplicas por participante
Dados	44 características acústicas da fonação sustentada da vogal /a/
Arquivo	CSV com aproximadamente 120,7 KB informados pela UCI

O dataset bruto não foi incluído no Git. A aquisição ocorre somente quando o usuário executa o notebook pela interface oficial da UCI ou fornece o CSV local.

O que foi entregue

- README em português com objetivo, escopo, referências e execução do zero.
- Ficha técnica com fonte, licença, variáveis, tamanho, privacidade, uso clínico e limitações.
- Avaliação FAIR com pontuação e justificativa para os quatro princípios.
- Ambiente Python 3.11 isolado e dependências diretas fixadas em requirements.txt.
- Notebook de EDA com inspeção estrutural, ausências, classes, participantes e réplicas.
- Análises preparadas por participante: distribuições, correlações, associações e PCA.
- Carregamento online por ucimlrepo e alternativa por CSV local fora do Git.
- Checklist que relaciona cada requisito do professor às evidências do repositório.

Decisão metodológica crítica

As 240 linhas não representam 240 indivíduos independentes. São 80 participantes com três gravações cada. As comparações principais são preparadas pela mediana das réplicas por participante. Em Machine Learning futuro, treino e teste deverão ser separados por ID com GroupKFold, StratifiedGroupKFold ou estratégia equivalente. Um split aleatório por linha poderia colocar gravações da mesma pessoa nos dois conjuntos e inflar o desempenho.

Uso clínico potencial e Machine Learning

- Aplicação potencial: suporte futuro à triagem não invasiva ou avaliação complementar; não é um instrumento diagnóstico validado.
- Entradas: jitter, shimmer, HNR, MFCC, delta-MFCC, RPDE, DFA, PPE e GNE.
- Alvo: Status, com 0 para controle e 1 para Parkinson.
- Agrupamento obrigatório: ID do participante; Recording identifica a réplica e não é biomarcador.
- Métodos relatados: regressão binária Bayesiana em nível de sujeito, probit com variáveis latentes, Gibbs sampling e seleção/classificação em duas etapas.

Avaliação FAIR

Princípio	Nota	Justificativa resumida
Findable	5/5	Página própria na UCI, metadados, identificador e DOI persistente.
Accessible	5/5	Acesso público por HTTPS, CSV e interface documentada.
Interoperable	4/5	CSV e variáveis numéricas, mas sem ontologia biomédica formal.
Reusable	4/5	CC BY 4.0, DOI e documentação; limitações amostrais e do desenho replicado.
Total	18/20	Boa encontrabilidade e acessibilidade, com limites semânticos e metodológicos registrados.

Privacidade e limitações

O CSV não apresenta identificadores pessoais diretos, mas contém ID pseudonimizado, sexo e condição de saúde. O risco de reidentificação é menor do que seria com áudio bruto, porém não é inexistente, especialmente quando combinado com fontes externas.

- amostra pequena e regional, com 80 participantes e 40 indivíduos por grupo;
- balanceamento artificial, que não representa prevalência clínica;
- três gravações dependentes por participante;
- participantes com mais de 50 anos e possível diferença de composição por sexo;
- apenas fonação sustentada da vogal /a/ e protocolo específico de gravação;
- características pré-extraídas, sem áudio bruto para repetir a extração;
- período de coleta não identificado claramente nas fontes consultadas;
- ausência de validação externa nesta entrega.

Reprodutibilidade e validações realizadas

Item	Situação
Repositório e histórico	Git na branch main e publicado no GitHub
Ambiente	Python 3.11.9 em .venv; ambiente fora do Git
Dependências	Versões fixadas e verificadas sem conflitos
Notebook	49 células; estrutura nbformat e sintaxe Python validadas
Portabilidade	Caminhos relativos; execução em VS Code, Jupyter ou Colab após clonar
Dados brutos	Não baixados e não versionados
Resultados	Nenhum resultado estatístico inventado ou pré-gravado

Estado da entrega

A documentação, o ambiente e o notebook estão prontos. Por decisão metodológica, a célula de aquisição não foi executada durante a preparação. Os resultados da EDA serão gerados somente quando o notebook for executado com acesso à UCI ou com o CSV local.

Referências essenciais

- [UCI 489 - Parkinson Dataset with replicated acoustic features](#).
- Naranjo et al. (2016). [Addressing voice recording replications for Parkinson's disease detection](#).
- Naranjo et al. (2017). [A two-stage variable selection and classification approach](#).
- Wilkinson et al. (2016). [The FAIR Guiding Principles](#).

Repositório da entrega

<https://github.com/B073LH0/detector-de-parkinson>